

Anexo metodológico N°2

En este anexo se presenta la metodología y los resultados del proceso de validación del uso de modelos de inteligencia artificial generativa para simular la codificación experta de intervenciones parlamentarias.

1. Resumen de la metodología para la validación de la codificación automatizada

Para validar la metodología de codificación de las intervenciones parlamentarias utilizando *large language models*, particularmente el modelo *Gemini 3.1 flash light preview*, se decidió usar como *benchmark* la codificación realizada por ambos investigadores. De este modo, se seleccionó aleatoriamente una muestra de 30 discursos –lo que por convención le da validez estadística a los test realizados– que fueron codificados con el mismo *prompt* (véase los N°1 y 2 del anexo metodológico N°1) por el modelo de IA generativa, así como por ambos investigadores de forma ciega.

Con los resultados de la codificación, se realizaron tres análisis estadísticos complementarios. En el primero, se obtuvieron para las categorías de contenidos –que admiten una sola respuesta– los porcentajes de acuerdo entre codificadores y para las de discurso –que admiten respuestas múltiples– los porcentajes observados por cada categoría. El segundo test consistió en calcular el indicador Kappa¹, métrica estándar para medir la confiabilidad inter-codificador. Finalmente, el tercer test, consistió en calcular si el nivel de desacuerdos entre los investigadores era significativamente distintivo –estadísticamente hablando– de los desacuerdos entre la IA y los investigadores, para esto, se usó el test de McNemar² para las categorías de contenido y el T-test pareado para las categorías de discurso, dada las diferencias ya señaladas respecto de la posibilidad o no de opciones múltiples.

La complementariedad de los tres test permite apreciar en su conjunto la validez de la metodología utilizada, usando la confiabilidad de codificación entre investigadores como el estándar de razonabilidad a igualar. A continuación, se presentan los detalles de cada test, y posteriormente los resultados.

2. Análisis de contenido

2.1. Los test

El porcentaje de acuerdo mide que proporción de la muestra fue codificada con el mismo valor entre un par de codificadores distintos, asumiendo que las codificaciones son independientes. Para medir esto, respecto de cada variable de contenido, se asignó el valor 1 para cuando un par de codificadores asignaron el mismo valor a la misma intervención, y 0 para cuando no, calculando luego el porcentaje de acuerdo entre pares de codificadores para cada variable.

¹ COHEN, J. (1960), *passim*.

² AGRESTI (1990), *passim*.

Por su parte, el indicador Kappa de Cohen mide el nivel acuerdo entre dos codificadores descontando el porcentaje de acuerdo que es esperable por azar³. El indicador se expresa formalmente de la siguiente manera

$$\kappa = \frac{P_o - P_e}{1 - P_e}$$

siendo P_e el porcentaje de acuerdo esperado por azar y P_o el acuerdo efectivamente observado. Para esto, se construyó una matriz con dos entradas por variable – una por cada codificador del par comparado - y se corrió la función *kappa2* del paquete *irr* de R para calcular el valor de kappa.

Finalmente, el Test de McNemar se usó para medir si el nivel de desacuerdos entre pares de codificadores era estadísticamente⁴, para lo cual se usaron los mismos valores 1 y 0 utilizados para el proceso descrito en el párrafo primero *supra* –que capturan el acuerdo/desacuerdo respectivamente– para calcular la probabilidad de que los desacuerdos entre pares de codificadores fueran o no estadísticamente significativos, utilizando la función *mcnemar.test* del paquete *stats* de R Studio para su cálculo.

2.2. Los resultados

Cómo se puede apreciar en la tabla 1 de resultados, solo en la variable “Tipo de respuesta” el porcentaje de acuerdo entre investigadores fue superior que entre investigadores e IA, en todas las demás hubo más acuerdo entre ambos investigadores y la IA –respectivamente– que entre los investigadores mismos.

Tabla 1. Porcentaje de acuerdo para Contenido

Codificador	Victimas	Enfoques	Tipo
I2-I1	10%	10%	10%
I2-IA	13.33%	30%	3.33%
I1-IA	23.33%	33.33%	6.67%

Por su parte, como muestra la Tabla 2, el indicador Kappa nos muestra porcentajes muy altos de acuerdo entre codificadores, tanto entre investigadores y entre estos y la IA, para todas las variables, salvo para enfoque, en que el nivel de acuerdo con la IA es inferior, sin dejar de mostrar niveles aceptables de acuerdo.

Tabla 2. Indicador Kappa de Cohen para Contenido

Categoría	I1-IA	I2-IA	I2-I1
Victima	0.5954	0.7633	0.8137
Enfoque	0.4048	0.46	0.7521
Tipo	0.8305	0.9088	0.7521

³ COHEN, J. (1960), p. 46.

⁴ AGRESTI (1990), *passim*.

Finalmente, como muestra la Tabla 3, el test de McNemar muestra que en ninguna de las variables de contenido desacuerdos entre investigadores y la IA que sean significativamente mayores que entre los investigadores mismos.

Tabla 3. Test de McNemar para Contenido

Categoría	Diver.1	Diver. 2	Chi ²	Valor P	Signific.
Victima	I2-IA	I2-I1	0	1	No
Victima	I1-IA	I2-I1	1	0.2888	No
Enfoque	I2-IA	I2-I1	2.5	0.1138	No
Enfoque	I1-IA	I2-I1	0	1	No
Tipo	I2-IA	I2-I1	1.5	0.2207	No
Tipo	I1-IA	I2-I1	0.5	0.6171	No

3. Análisis de discurso

3.1. Los test

Respecto del análisis de los elementos discursivo, a saber, conexiones, prácticas y valoraciones, por tener los datos una estructura distinta (admitiendo opciones múltiples), los test realizados –si bien siguen una lógica similar– presentan ciertas diferencias que se detallan a continuación.

Dado que, para cada intervención, el codificador podía elegir hasta 5, 3 y 3 categorías de una lista de 13, 8 y 8 que poseía el libro de códigos asignado a cada variable, se optó por mostrar en este primer test el porcentaje que cada valor ocupó sobre el total de intervenciones, siendo 30 el número máximo de apariciones en la muestra y 0 el mínimo. Eso muestra si entre codificadores hubo patrones similares respecto de la prevalencia de ciertas categorías sobre otras.

Luego, el test de Kappa se siguió la misma metodología que la desarrollada en el acápite 2.1 *supra*, con la diferencia que los datos tuvieron que ser transformados. De esta forma, se construyó una matriz por cada variable, a saber, conexiones, prácticas y valoraciones, cada una con tantas columnas como categorías en el respectivo libro de códigos, y tres filas por intervención, una por cada codificador. En cada celda se asignó el valor 1 si el codificador identificó dicha categoría para esa intervención, y 0 si no. Con la matriz así construida, se aplicó el mismo test ya detallado.

Finalmente, en vez del test de McNemar que es sólo apto para opciones dicotómicas, para estas variables que aceptaban opciones múltiples, se calculó el porcentaje de acuerdo de la IA con los codificadores humanos, entendido como el porcentaje de categorías en que la IA coincidió con el investigadores sobre el total de categorías que identificó este último. Sobre estos valores se aplicó un T-Test pareado para identificar si los porcentajes de desacuerdo entre IA e investigadores eran estadísticamente diferentes respecto del desacuerdo entre investigadores, a un nivel de confianza del 95%.

3.2. Los resultados

Como se puede apreciar en la Tabla 4, existen bastante dispersión entre los tres codificadores (ambos investigadores incluidos) en cuanto a la distribución de las categorías identificadas en la muestra de intervenciones analizadas para la variable de Conexiones.

Tabla 4. Porcentajes observados para Conexiones

Conexión	% IA	% I1	% I2
Sin conexión clara	20%	23.33%	23.33%
Crisis de Seguridad	36.67%	20%	13.33%
Estándares Internacionales	16.67%	16.67%	3.33%
Garantismo	16.67%	6.67%	3.33%
Impunidad	33.33%	20%	16.67%
Ideas de Justicia	40%	26.67%	56.67%
Olvido de la víctima	23.33%	33.33%	0%
Peligro	0%	13.33%	20%
Pérdida de valores	3.33%	3.33%	3.33%
Prevención	6.67%	3.33%	0%
Reinserción	0%	3.33%	0%
Mal causado	30%	16.67%	13.33%
Victimización secundaria	56.67%	33.33%	46.67%

De lo anterior se desprende que, para algunas categorías, como garantismo, el nivel de acuerdo medido por Kappa sea tan bajo, como muestra la Tabla 5. Ahora bien, cabe tener presente que el método de Cohen castiga la poca variabilidad, es decir, si ambos codificadores anotan 0 para una variable en todas las observaciones, pero no coinciden en los únicos dos valores 1 que identificaron, aquello se tomará como bajo acuerdo, aunque hayan coincidido en todos los 0.⁵ Con todo, cabe destacar en la Tabla 5 los altos niveles de acuerdo, muchas veces mayor entre un investigador y la IA, en las categorías más preponderantes de la Tabla 4, como “Crisis de Seguridad”, “Impunidad” o “Victimización secundaria”.

Tabla 5. Indicador Kappa de Cohen para Conexiones

Conexión	I1-IA	I2-IA	I2-I1
Sin conexión clara	0.9	0.9	0.81
Crisis de Seguridad	0.6	0.25	0.52
Estándares Internacionales	0.76	0.29	0.29
Garantismo	-0.11	-0.06	-0.05
Impunidad	0.5	0.57	0.44
Ideas de Justicia	0.12	0.03	0.44
Olvido de la víctima	-0.05	0	0
Peligro	0	0	0.52
Pérdida de valores	1	1	1
Prevención	-0.05	0	0
Reinserción	0	∞	0
Mal causado	0.45	0.15	0.61
Victimización secundaria	0.55	0.8	0.73

⁵ COHEN, J. (1960), *passim*.

Respecto de la variable Prácticas, si bien persiste cierta dispersión, es menor que para Conexiones, tal y como se puede apreciar en la Tabla 6.

Tabla 6. Porcentajes observados para Prácticas

Práctica	% IA	% I1	% I2
Sin prácticas claras	20%	20%	20%
Describir la ley	33.33%	0.2667	20%
Agradecimiento	10%	16.67%	13.33%
Toma de posición	73.33%	50%	30%
Atribuyendo autoría	0%	6.67%	6.67%
Denuncia	20%	16.67%	23.33%
Llamado a la acción	36.67%	16.67%	26.67%
Ponerse del lado de las víctimas	33.33%	0%	40%

Lo anterior, igualmente se ve reflejado en la Tabla 7 que muestra notablemente niveles más altos de acuerdo entre codificadores, con excepción de la categoría “Atribución de autoría” y “Ponerse del lado de las víctimas”, con excepción del investigador I2-IA.

Tabla.7 Indicador Kappa de Cohen para Prácticas

Práctica	I1-IA	I2-IA	I2-I1
Sin prácticas claras	1	1	1
Describir la ley	0.53	0.5	0.81
Agradecimiento	0.71	0.52	0.87
Toma de posición	0.53	0.27	0.2
Atribuyendo autoría	0	0	-0.07
Denuncia	0.67	0.51	0.38
Llamado a la acción	0.19	0.31	0.52
Ponerse del lado de las víctimas	0	0.43	0

Finalmente, en valoraciones volvemos a ver categorías con altos niveles de dispersión entre codificadores. Por ejemplo la IA asignó a un 56.67% de las intervenciones la valoración “Se reconoce inocencia”, cuando el I1 0% y el I2 3.33%, el I1 asignó a un 0% de las intervenciones “División buenos y malos” cuando el I2 lo hizo un 20% y la IA un 23.33%. Con todo, categorías como “Víctima es digna de compasión” recibieron porcentajes similares entre los tres codificadores. Llama la atención que en la muestra dos categorías no recibieron ninguna asignación para ningún de los tres codificadores.

Tabla 8. Porcentajes observados para Valoraciones

Valoración	% IA	% I1	% I2
Sin valoración claras	26.67%	36.67%	26.67%
Reconoce agencia a la víctima	10%	0.2667	20%
Víctima es digna de compasión	16.67%	10%	13.33%
División de buenos y malos	23.33%	0%	20%
Víctima como vulnerable	70%	46.67%	60%
Indeseabilidad	0%	0%	0%
Se reconoce inocencia	56.67%	0%	3.33%

Se le atribuye responsabilidad	0%	0%	0%
--------------------------------	----	----	----

De lo anterior, se puede apreciar en la Tabla 9 altos niveles de acuerdo, acompañados de altos niveles de desacuerdo, y también valores Kappa que no pudieron calcularse porque requieren un mínimo de variabilidad – lo que no tuvo “Indeseabilidad” y “Se le atribuye responsabilidad”.

Tabla 9. Indicador Kappa de Cohen para Valoraciones

Valoración	I1-IA	I2-IA	I2-I1
Sin valoración claras	0.77	1	0.77
Reconoce agencia a la víctima	0.26	0.62	0.44
Víctima es digna de compasión	-0.14	0.35	-0.13
División de buenos y malos	0	0.9	0
Víctima como vulnerable	0.42	0.78	0.47
Indeseabilidad	∞	∞	∞
Se reconoce inocencia	0	0.05	0
Se le atribuye responsabilidad	∞	∞	∞

Finalmente, en la Tabla 10, el valor T representa la dirección de la diferencia, esto quiere decir que el T-Test pareado nos muestra que los niveles de desacuerdo entre la IA y ambos investigadores fueron significativamente más bajos que entre los mismos investigadores para la variable de Conexiones, al igual que entre el I2 y la IA para la variable Práctica. Luego, no hubo diferencias estadísticamente significativas entre el I1 y la IA en Práctica y entre I2 e IA en Valoración. Solo el desacuerdo fue mayor entre la IA y un investigador respecto del I1 en la variable Valoración.

Tabla 10. T-Test pareado

Categoría	Diver.1	Diver.2	Valor T	Valor P	Significancia
Conexión	I2-IA	I2-I1	-1.6425	0.1113	Si
Conexión	I1-IA	I1-I2	-3.9999	0.0004002	Si
Practica	I2-IA	I2-I1	-3.9697	0.0004343	Si
Practica	I1-IA	I1-I2	1.573	0.1266	No
Valoración	I2-IA	I2-I1	1	0.4226	No
Valoración	I1-IA	I1-I2	6.3938	6.386e-07	Si

4. Revisión del desacuerdo

Finalmente, los desacuerdos entre los investigadores y la IA fueron en la muestra de intervenciones fueron analizados manualmente por los investigadores verificándose la plausibilidad de la discrepancia. Esto se debe a las sutilezas del lenguaje que permiten interpretaciones múltiples, muchas veces de las cuales son todas correctas, sin poder reducir a 0 la incertidumbre en trabajos de análisis cualitativos de textos como este.

5. Conclusiones

Los resultados muestran que, utilizando el modelo Gemini 3.1-flash-lite-preview, no existían diferencias estadísticamente significativas entre la codificación realizada por la IA y la realizada por los autores. En aquellos casos en que se observaron diferencias, la convergencia

entre la IA y los codificadores humanos fue igual o superior a la observada entre los propios codificadores humanos. Cabe señalar que el nivel de acuerdo inter codificador entre los autores fue particularmente bajo en algunas de las variables de discurso. No obstante, una revisión cualitativa de los casos discrepantes indicó que las categorías asignadas por la IA tendían a corresponder a interpretaciones plausibles del material analizado, aun cuando difieran de las seleccionadas por los codificadores humanos.

